



浙江工商大学

硕士学位论文

论文题目：基于扩散模型的三维药物分子设计框架

作者姓名：徐璨

学科专业：统计学

研究方向：数理统计

指导教师：王伟刚

提交日期：2024 年 1 月

**Dissertation Submitted to Zhejiang Gongshang University
for Master's Degree of Science**

A Diffusion-based 3D Molecule Generative Framework

Author: Can Xu

Major: Statistics

Supervisor: Prof. Weigang Wang



Jan. 2024

School of Statistics and Mathematics

Zhejiang Gongshang University

Hangzhou, 310018, P. R. China

基于扩散模型的三维药物分子设计框架

摘 要

近年来基于深度学习的生成模型也在多领域有成功应用，例如 AI 在图画、语音、视频、对话等应用上的优秀表现引发了社会对人工智能新一轮广泛关注与热烈讨论。

在智能计算的计算医药相关研究中，深度学习模型在药物发现、药物属性预测等应用中已经展现出良好的性能和极大的潜力。人工智能技术应用能够为药物研发的多个阶段降本增效。过去的 2022 年，AI 制药赛道相关融资总金额达百亿美元。国内互联网巨头如百度百图生科、华为 EIHealth、腾讯云深智药，及初创企业晶泰科技，剂泰医药，星药科技等，相关成果已经展现出深度学习在该领域的强大性能和广阔前景。

近来大火的生成模型被广泛应用于智能计算领域，人工智能算法有望根据人类的要求生成理想的结果，帮助提升药物发现与设计的效率与质量。在计算化学的相关研究中，深度学习模型的成功落地能够推动制药企业减少湿实验成本，助力靶点确认、药物发现、分子生成、化学反应设计、化合物筛选、临床试验、风险评估等多阶段。

本文聚焦于深度学习算法在三维药物分子发现这一主题，意在利用时下最优的生成模型算法，创新性设计出更符合三位药物理化性质的算法，提升全新药物分子设计的性能与效率。

关键词: 扩散模型; 分子生成; 几何神经网络

A DIFFUSION-BASED 3D MOLECULE GENERATIVE FRAMEWORK

ABSTRACT

AAAAAAAAAAAAAA

KEYWORDS: Diffusion model; Molecule generation; Geometry neural network

第1章 引言

1.1 选题背景与研究意义

1.1.1 选题背景

除图像、视频，音频与自然语言处理等领域，AI 技术的快速发展也带动相关交叉学科的发展。AI4Science 近年在计算生物、计算化学、材料设计、计算天文，计算育种等都有广泛应用，相关 AI 技术的应用能够大幅加速相关科学研究进展。在计算制药领域，近年来相关 AI 技术在药物性质预测，生成，开发，实验等领域的运用不仅加速相关研究的进展，也能够降低相关研究的研发成本。

基于 AI 的生成模型近十年来也被广泛研究，他们包括变分自编码器 (Variational autoencoders / VAEs)^[1]，生成对抗模型 (Generative adversarial networks / GANs)^[2]，流形模型 (Normalizing flows / NFs)^[3-4]，自回归 (Autoregressive models / ARs)^[5] 与扩散模型 (Diffusion)^[6-7] 等。相关方法在图像，文字等方面也有了许多成功应用。

深度学习在分子化学领域近年来也有着成功的应用。以分子学习为例，化学分子常以简化分子线性输入规范字符串 (Simplified molecular-input line-entry system / SMILES)^[8] 存储，每一个分子式对应一个 SMILES 字符串。随着早期深度学习方法，如卷积神经网络 (Convolutional neural networks / CNNs)^[9] 和循环神经网络 (Recurrent neural networks / RNNs)^[10-12] 的发展，一些研究试图运用这些深度学习算法，对以字符串形式存在的分子式进行学习，以获得预测特定原子或是分子整体的性质的能力。随着图神经网络 (Graph neural networks / GNNs)^[13-15] 的出现，其对非结构化数据的建模能力和对节点间拓扑关系学习的能力被证明十分优异。分子作为自然界中天然存在的图结构，原子和键对应着图中的节点和边，这为分子学习提供了新的思路与方法。从最早的图卷积神经网络开始，相关研究者致力于提出新的图学习算法，以提升对分子图学习的性能。随着相关化学模拟技术的发展，让三维分子建模成为可能。这也在拓扑结构信息以外，提供了更丰富的几何构型信息，这也驱动着相关研究拓展至几何图神经网络上。分子三维构象允许研究者对分子进行更准确的研究，同时也推动更多复杂任务的出现，包括分子生成，Ligand 生成，Protacs 生成，药物亲和力预测，蛋白质预测等等。

1.1.2 研究意义

人工智能在智能计算相关研究中开始扮演越来越重要的角色，相关模型在药物发现、药物属性预测等应用中已经展现出良好的性能和极大的潜力。由于深度学习技术应用具备为药物研发的多阶段降本增效的潜力，在 2022 年，AI 制药赛道相关企业融资总金额达百亿美元。在这一赛道竞逐的有国内互联网巨头如百度、百图生科、华为 EIHealth、腾讯云深智药，及初创企业晶泰科技，剂泰医药，星药科技等。相关成果已经展现出深度学习在该领域的强大性能和广阔前景。

1.2 文献综述

1.2.1 基于深度学习的分子学习

分子最早被表示为简化分子线性输入规范字符串 (SMILES)^[8]，随着早期深度学习模型卷积神经网络 (CNN) 和循环神经网络 (RNN) 的发展，相关模型利用 CNNs 和 RNNs 对分子性质做出学习。Hirohara 等^[9]的研究提出使用 CNN 对分子级别的特征和分子基团性质进行有效学习。由于 RNNs 在早期自然语言护理任务上有良好表现，Bjerrum^[10]提出 LSTM-QSAR 模型用于学习分子性质。

伴随图神经网络 (GNNs) 的发展，由于分子的形式天然的属于图结构，一些研究开始使用 GNNs 进行分子学习。CGCNN^[16]将图卷积神经网络引入到分子性质学习，用以模拟并替代复杂的 DFT 计算。Xiong 等^[17]提出 Attentive FP，一个结合注意力机制的图神经网络实现分子性质的有效学习与预测。GraSeq^[18]提出在运用图神经网络学习拓扑结构同时，利用双向 LSTM 模型对 SMILES 分子式进行学习，通过两个通道联合预测分子性质。伴随相关技术的发展，研究者可以不再拘泥于原子拓扑结构，进而实现对分子三维结构的建模与学习。鉴于某一分子对应大量的同分异构体，而不同构象对应属性不尽相同，因此对三维构象的有效学习是十分必要的。EGNN^[19]在流行的图网络基础上，保留最基本的几何信息，即原子间距离，其简单的设计也成为了一些。在分子预训练框架 GEM^[20]中，研究者提出 GeoGNN 图网络，将键长视作原子节点图的边特征，又对原子键构图，并将键角作为原子键图的边特征，通过在两个网络上的信息传递实现分子局部空间几何性质学习。Schütt 等^[21]在继承 GNNs 的信息传递范式的同时，将原子间距离用径向基函数 (Radial basis function / RBF) 建模后融入边特征，使算法对三维几何信息的有效学习的同时保证了等变性要求。SphereNet^[22]提出了基于球坐标系的信息传递范式 SMP。通过一系列参考原子或键的规则，SMP 在保证对原子

对距离，键角和键扭转角这三个空间几何信息完整提取的同时，避免计算复杂度的爆炸式增长。ComENet^[23]在 ShpereNet 的基础上，简化了空间几何信息的提取范式，在保证利用完整空间信息的前提下，以损失部分精度为代价，大幅度提升计算速度。

伴随着 Transformer^[24] 相关研究在图像与文本领域的兴起，相关研究^[25-27] 也利用 Transformer 对 SMILES 分子式进行学习。随着 GTN^[28] 将 Transformer 引入图学习，越来越多的研究也将多头注意力机制用于分子图学习领域。大规模分子图预训练框架 GROVER^[29] 中，分子学习内核运用了 GTransformer，同时学习分子中的原子与键的节点嵌入 (embedding) 或边嵌入。在分子预训练框架 MPG^[30] 中提出的图学习内核 MolGNet 放弃了对边嵌入的学习，仅利用多头注意力学习节点嵌入，结果证明了该图学习算法的有效性。

1.2.2 基于深度生成模型的分子设计

自深度学习研究兴起以来，深度生成模型一直是研究者重点研究的对象。作画、翻译、对话，渲染等应用能够直接服务于广大用户。主流的深度生成模型有变分自编码器 (Variational autoencoders / VAEs)^[1]，生成对抗模型 (Generative adversarial networks / GANs)^[2]，流形模型 (Normalizing flows / NFs)^[3-4]，自回归 (Autoregressive models / ARs)^[5] 与扩散模型 (Diffusion)^[6-7] 等。

与图学习的演进过程相似，基于深度生成模型的分子设计也经历了从二维图结构到三维几何构象的演进。主流分子设计任务具体又可以被细分为：分子生成，分子优化，构象生成，蛋白质配体生成，蛋白质生成，蛋白降解靶向嵌合体生成。

分子生成的任务就是根据给定分子数据，使模型具备凭空生成全新且有效的药物分子图或三维结构。考虑到复杂药物分子主要由官能团等子结构组成，JT-VAE^[31] 基于 VAE 生成树结构骨架，而后利用树结构骨架逐步生成分子图结构。GraphVAE^[32] 是早期的基于 VAE 的图生成研究，为避免离散化结构的线性表示的相关障碍，使其中解码器直接输出预设的最大概率的全连接图。基于 NF 模型，MoFlow^[33] 将隐式表征逐步映射到条件流过程中，模型首先生成连接原子的键，随后通过图条件流生成原子，并最终组成有效的分子图。

现有的基于扩散的分子生成模型较少，此领域最早的研究为 EDM^[34]，其基于 EGNN^[19] 的去噪过程内核，通过生成点云，再根据预设定的化学性质生成连接边的键。MDM^[35] 在此基础上，提出了全新的去噪内核，通过两个 SchNet^[21] 分别对局部节点和全局节点特征进行学习。由于这种扩散模型更擅长在连续样本空间上的学习，故主流方法并不直接预测分子图中边的存在性，针对这一问题，DiGress^[36] 和

MiDi^[37] 提出将图邻接矩阵引入扩散过程, 并相应将马尔可夫状态转移矩阵引入噪声序列而非传统的高斯噪声。GCDM^[38] 针对对空间几何信息提取不足的问题, 引入 ColfNet^[39] 相似的空间几何学习范式, 实现了对几何信息的充分学习。

1.2.3 扩散模型

在图学习领域中, 一个图可以被表示为一个元组 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$, 其中包含了一个节点集合 \mathcal{V} 和一个边集合 \mathcal{E} 。在训练阶段, 模型学习图在扩散过程中的概率分布, 并被用于后续的采样阶段, 以迭代地方式生成新的图。基于扩散的生成模型因其在多个领域的生成任务中表现出色而受到广泛关注, 例如计算机视觉^[40-43], 自然语言处理^[44-46], 以及其他各种跨学科任务等^[47-49]。

人体骨架的表示形式与分子类似, 都是表示为被边连接起的点云。不同之处在于生成人体骨架动作时, 不需要对边的存在性进行预测。基于扩散模型, MoFusion^[50] 在人体动作生成中使用 U-Net^[51] 作为扩散模型中去噪核心的架构。MoDi^[52] 利用结构感知神经滤波器和 3D 卷积, 实现对每个关节的精确控制。

除了在分子生成和人体动作生成上的应用外, 许多研究工作致力于将扩散过程用于其他形式的图数据生成。SaGess^[53] 通过引入广义分治框架来增强 DiGress^[36]。对于 2D 图生成, EDP-GNN^[54] 将 Score SDEs 结合到离散图邻接矩阵生成中。在此基础上, GraphGDP^[55] 提出了名为 Position-enhanced 图得分网络的去噪核心, 以实现位置信息的进一步利用。GSMD^[56] 不仅仅在边属性上进行采样, 还利用了节点特征和图谱空间上的 Score SDE 高效地生成图, 这在通用数据集和分子数据集上得到了验证。受 VAEs 启发, NVDiff^[57] 采用 VGAE 结构, 首先对图在隐变量空间上的特征进行采样, 然后将其解码为节点或边特征。SLD^[58] 以类似的方式进行图生成任务。GraphARM^[59] 通过引入节点吸收扩散过程, 将自回归模型与扩散模型结合起来。EDGE^[60] 将扩散模型引入大图生成, 扩散过程中逐渐移除边, 直到图为空。该模型还通过仅关注部分节点来避免生成过多的边。专为双曲图设计的 HGDM^[61] 在提取双曲嵌入的复杂几何特征方面表现出优良的性能。

1.3 创新点

在本文中, 我们提出了用于 3D 分子生成的 “Geometric-facilitated Molecular Diffusion” (GFMDiff) 框架。与先前的方法主要基于原子对距离学习原子特征不同, 本文成功地将三元几何信息与原子对距离有效地结合到分子学习中。本领域大多数研究在生成式直接生成点云, 并根据预设规则完成 3D 图结构的搭建。然而

这种方法存在两个主要问题。首先，间接的图生成方式导致样本的稳定性和有效性下降。其次，传统的图卷积不足以区分局部和全局信息。为了解决第一个约束，本文设计了一个精巧的损失函数“Geometric-facilitated Loss” (GFLoss)，在训练阶段主动引导键的形成。至于第二个约束，我们引入了“Dual-track Transformer Network” (DTN)，这是一个基于全局 Transformer 的神经网络，以促进全面的几何学习和局部特征学习。

1.4 基本框架

本文可分为四章，每章的主要内容如下：

第一章为引言，本文在该部分介绍了分子生成的研究背景及意义，相关研究领域的研究现状及本文的主要创新点。

第二章中，本文在该部分介绍了分子图与扩散模型等预备知识。

第三章中，本文在该部分介绍了本文提出的 GFMDiff 框架。

第四章中，本文在该部分介绍了本文的 GFMDiff 模型分子生成任务中的表现及其中去噪核心 DTN 在分子学习任务上的表现。

第五章中，本文在该部分总结了本文研究的内容，并对未来发展做出展望。

第2章 分子图学习与基于扩散模型的图生成

2.1 分子图学习

在图学习中通常有两类监督任务：节点分类/回归和图分类/回归。对于图学习，一个分子可以被抽象为一个图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ ，其中 $|\mathcal{V}| = n$ 表示节点（原子）的集合， $|\mathcal{E}| = m$ 表示分子中的边（化学键）的集合。我们用 e_i 表示节点 i 的特征，用 e_{ij} 表示边 (i, j) 的特征。

在节点分类或回归任务中，每个节点 i 都有一个标签或目标 y_i 。任务目标是通过学习，预测未见节点的标签。这个任务可被应用于许多应用，比如识别分子中的功能团或预测各个原子的性质。

此外，在图分类或回归任务中，给定一组图 $\{\mathcal{G}_1, \mathcal{G}_2, \dots, \mathcal{G}_N\}$ 和对应的标签或目标 $\{y_1, \dots, y_N\}$ 。此时任务目标是根据图的结构和节点边的特征，预测给定图的标签或目标。这个任务被广泛应用于化合物分类或基于结构预测分子性质等。

在这两类任务中，目标是利用监督学习技术训练模型，有效地捕捉图的结构与相关标签/目标之间的关系。现有的图学习方法主要有基于图神经网络的模型和基于 Transformer 架构的模型。

图神经网络 (Graph Neural Networks, 简称 GNNs)，近来在知识图谱、社交网络和药物发现等各个领域引起了广泛的关注。GNNs 的核心操作在于将图中节点或边之间的特征进行传递（也称为邻居聚合）。消息传递操作通过聚合节点 i 的邻居节点和边的隐式特征来迭代更新节点 i 自身的隐式特征 e_i 。一般来说，消息传递过程包含多轮迭代，每轮迭代可以被视为对更远距离邻居的消息聚合。假设有 L 轮迭代，第 l 轮迭代会将目标节点的 1 跳邻居特征注入目标节点的隐式特征。第 l 轮迭代中，消息的传递与聚合可被表示为：

$$m_j^{(l)} = \text{MSG}^{(l)}(e_j^{(l-1)}), j \in \mathcal{N}_i, \quad (2.1)$$

$$e_i^{(l)} = \text{AGG}^{(l)}(\{m_j^{(l)}, j \in \mathcal{N}_i\}, m_i^{(l)}), \quad (2.2)$$

其中 $m_j^{(l)}$ 为聚合后的消息，MSG 为消息聚合函数，主流的选择包括多层感知机 (MLP)，可学习权重。 $e_i^{(l)}$ 为聚合后的目标节点特征，AGG 为聚合函数，主流的方式有平均值池化、最大池化和图注意力机制等。对每一次消息传递，MSG 和 AGG 函数都可能存在可训练的参数，这些参数在每轮迭代中一般是共享的。经过 L 次

消息传递与聚合后，最后一次迭代后的隐式特征被视为模型预测的节点嵌入，即 $e_i^{(L)}$ 。最后，根据具体任务需要，运用相应的 READOUT 函数即可得到节点信息或是全图级别的信息。

近年来，伴随 Transformer 模型的出现，一些研究也开始将该架构引入图学习中。多头注意机制是 Transformer 的核心模块，它将多个注意力层堆叠在一起，实现并行运算。一个注意力层的核心要素一般为一组查询、键、值组成，记为 $(\mathbf{Q}, \mathbf{K}, \mathbf{V})$ 。通过查询和键的点积，经过 softmax 函数归一化后即可获得注意力概率，具体可表示为：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q} \cdot \mathbf{K}^T}{\sqrt{d}}\right) \cdot \mathbf{V}, \quad (2.3)$$

其中 d 为注意力头数。

2.2 基于扩散模型的图生成

扩散模型在生成模型中引起了相当大的关注。通过学习逆过程的去噪核，这些模型能够揭示噪声样本的潜在分布。在给定一段数据的情况下，正向过程被视为马尔可夫链，通过学习可学习参数控制噪声强度，逐渐向数据添加高斯噪声 T 次。在生成过程中，模型将噪声还原回真实数据的原始分布。

2.2.1 扩散过程

设 $G_t (t = 0, 1, \dots, T)$ 表示分子几何信息的分布， $\beta_t \in (0, 1), t = 0, 1, \dots, T$ 表示马尔可夫链的噪声方差序列。因此我们可以得到几何信息在 t 或 T 时刻在后验分布：

$$q(G_{1:T}|G_0) = \prod_{t=1}^T q(G_t|G_{t-1}), \quad (2.4)$$

$$q(G_t|G_{t-1}) = \mathcal{N}(G_t; \sqrt{1 - \beta_t} G_{t-1}, \beta_t I). \quad (2.5)$$

随着时间步 t 的增加，噪声方差 β_t 从 0 平滑地过渡到 1，这意味着向原始数据分布添加更多噪声。设 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s = \prod_{s=1}^t (1 - \beta_s)$ ，样本数据的分布可以表示为：

$$q(G_t|G_0) = \mathcal{N}(G_t; \sqrt{\bar{\alpha}_t} G_0, (1 - \bar{\alpha}_t) I). \quad (2.6)$$

去噪过程

在去噪过程中，模型通过学习接近实际逆过程 $q(G_{t-1}|G_t)$ 的马尔可夫核函数 $p_\theta(G_{0:T-1}|G_T) = \prod_{t=1}^T p_\theta(G_{t-1}|G_t)$ 来重新构建原始的几何信息。每个时间步骤中学习到的参数化动力学的分布为：

$$p_\theta(G_{t-1}|G_t) = \mathcal{N}(G_{t-1}; \mu_\theta(G_t, t), \sigma_t^2 I), \quad (2.7)$$

其中 $\mu_\theta(G_t, t)$ 是用于近似均值的神经网络， $\sigma_t^2 = \frac{(\beta_t - \beta_{t-1})\beta_{t-1}}{(1 - \beta_{t-1})\beta_t}$ 是预定义的方差进度。初始时， $p_\theta(G_t)$ 从标准高斯分布中采样得到。然后通过迭代的逆过程逐步优化几何信息和原子特征。

理论上，训练目标采用数据对数似然的变分下界形式：

$$\log p(G) \geq \mathcal{L}_{base} + \sum_{t=0}^T \mathcal{L}_t, \quad (2.8)$$

$$\mathcal{L}_{base} = -KL(q(G_T|G_0)|p(G_T)), \quad (2.9)$$

$$\mathcal{L}_t = KL(q(G_{t-1}|G_t)|p(G_{t-1}|G_t)). \quad (2.10)$$

然而，研究发现，预测高斯噪声 ϵ 能够更容易进行神经网络训练。因此， \mathcal{L}_t 的形式为

$$\mathcal{L}_t = E_{\epsilon_t \sim \mathcal{N}(0, I)} \left[\frac{1}{2} \left(1 - \frac{\text{SNR}(t-1)}{\text{SNR}(t)} \right) \|\epsilon_t - \hat{\epsilon}_t\|^2 \right]. \quad (2.11)$$

参考文献

- [1] KINGMA D P, WELLING M. Auto-encoding variational bayes[A]. 2013. arXiv: 1312.6114.
- [2] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//GHAHRAMANI Z, WELLING M, CORTES C, et al. Advances in Neural Information Processing Systems: Vol. 27. Curran Associates, Inc., 2014.
- [3] DINH L, KRUEGER D, BENGIO Y. Nice: Non-linear independent components estimation. arxiv e-prints, 2014[C]//Published as a conference paper at the 3rd International Conference for Learning Representations, San Diego. 2015.
- [4] DINH L, SOHL-DICKSTEIN J, BENGIO S. Density estimation using real NVP[C]//International Conference on Learning Representations. 2017.
- [5] VAN DEN OORD A, KALCHBRENNER N, KAVUKCUOGLU K. Pixel recurrent neural networks[C]//BALCAN M F, WEINBERGER K Q. Proceedings of Machine Learning Research: Vol. 48 Proceedings of The 33rd International Conference on Machine Learning. New York, New York, USA: PMLR, 2016: 1747-1756.
- [6] SOHL-DICKSTEIN J, WEISS E, MAHESWARANATHAN N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[C]//BACH F, BLEI D. Proceedings of Machine Learning Research: Vol. 37 Proceedings of the 32nd International Conference on Machine Learning. Lille, France: PMLR, 2015: 2256-2265.
- [7] SONG Y, ERMON S. Generative modeling by estimating gradients of the data distribution[C]//WALLACH H, LAROCHELLE H, BEYGELZIMER A, et al. Advances in Neural Information Processing Systems: Vol. 32. Curran Associates, Inc., 2019.
- [8] WEININGER D. Smiles, a chemical language and information system. 1. introduction to methodology and encoding rules[J/OL]. Journal of Chemical

-
- Information and Computer Sciences, 1988, 28(1): 31-36. DOI: 10.1021/ci00057a005.
- [9] HIROHARA M, SAITO Y, KODA Y, et al. Convolutional neural network based on smiles representation of compounds for detecting chemical motif [J/OL]. BMC bioinformatics, 2018, 19: 83-94. DOI: 10.1186/s12859-018-2523-5.
- [10] BJERRUM E J. Smiles enumeration as data augmentation for neural network modeling of molecules[A]. 2017. arXiv: 1703.07076.
- [11] LIU S, ALNAMMI M, ERICKSEN S S, et al. Practical model selection for prospective virtual screening[J/OL]. Journal of Chemical Information and Modeling, 2019, 59(1): 282-293. DOI: 10.1021/acs.jcim.8b00363.
- [12] HUANG K, FU T, GLASS L M, et al. Deeppurpose: a deep learning library for drug-target interaction prediction[J/OL]. Bioinformatics, 2020, 36(22-23): 5545-5547. DOI: 10.1093/bioinformatics/btaa1005.
- [13] KIPF T N, WELLING M. Semi-supervised classification with graph convolutional networks[C]//International Conference on Learning Representations. 2017.
- [14] HAMILTON W, YING Z, LESKOVEC J. Inductive representation learning on large graphs[C]//GUYON I, LUXBURG U V, BENGIO S, et al. Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.
- [15] XU K, HU W, LESKOVEC J, et al. How powerful are graph neural networks? [C]//International Conference on Learning Representations. 2019.
- [16] XIE T, GROSSMAN J C. Crystal graph convolutional neural networks for an accurate and interpretable prediction of material properties[J/OL]. Phys. Rev. Lett., 2018, 120: 145301. DOI: 10.1103/PhysRevLett.120.145301.
- [17] XIONG Z, WANG D, LIU X, et al. Pushing the boundaries of molecular representation for drug discovery with the graph attention mechanism[J/OL].

Journal of Medicinal Chemistry, 2020, 63(16): 8749-8760. DOI: 10.1021/acs.jmedchem.9b00959.

- [18] GUO Z, YU W, ZHANG C, et al. Graseq: Graph and sequence fusion learning for molecular property prediction[C/OL]//CIKM '20: Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York, NY, USA: Association for Computing Machinery, 2020: 435–443. DOI: 10.1145/3340531.3411981.
- [19] SATORRAS V G, HOOGEBOOM E, WELLING M. E(n) equivariant graph neural networks[C]//MEILA M, ZHANG T. Proceedings of Machine Learning Research: Vol. 139 Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 9323-9332.
- [20] FANG X, LIU L, LEI J, et al. Geometry-enhanced molecular representation learning for property prediction[J]. Nature Machine Intelligence, 2022, 4(2): 127-134.
- [21] SCHÜTT K, KINDERMANS P J, SAUCEDA FELIX H E, et al. Schnet: A continuous-filter convolutional neural network for modeling quantum interactions[C]//GUYON I, LUXBURG U V, BENGIO S, et al. Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.
- [22] LIU Y, WANG L, LIU M, et al. Spherical message passing for 3d molecular graphs[C]//International Conference on Learning Representations. 2022.
- [23] WANG L, LIU Y, LIN Y, et al. ComENet: Towards complete and efficient message passing for 3d molecular graphs[C]//OH A H, AGARWAL A, BELGRAVE D, et al. Advances in Neural Information Processing Systems. 2022.
- [24] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Advances in Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017.
- [25] HONDA S, SHI S, UEDA H R. Smiles transformer: Pre-trained molecular fingerprint for low data drug discovery[A]. 2019. arXiv: 1911.04738.

-
- [26] WANG S, GUO Y, WANG Y, et al. Smiles-bert: Large scale unsupervised pre-training for molecular property prediction[C/OL]//BCB '19: Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics. New York, NY, USA: Association for Computing Machinery, 2019: 429–436. DOI: 10.1145/3307339.3342186.
- [27] CHITHRANANDA S, GRAND G, RAMSUNDAR B. Chemberta: Large-scale self-supervised pretraining for molecular property prediction[A]. 2020. arXiv: 2010.09885.
- [28] YUN S, JEONG M, KIM R, et al. Graph transformer networks[C]//WALLACH H, LAROCHELLE H, BEYGELZIMER A, et al. Advances in Neural Information Processing Systems: Vol. 32. Curran Associates, Inc., 2019.
- [29] RONG Y, BIAN Y, XU T, et al. Self-supervised graph transformer on large-scale molecular data[C]//Advances in Neural Information Processing Systems: Vol. 33. Curran Associates, Inc., 2020: 12559-12571.
- [30] LI P, WANG J, QIAO Y, et al. An effective self-supervised framework for learning expressive molecular global representations to drug discovery[J/OL]. Briefings in Bioinformatics, 2021, 22(6). DOI: 10.1093/bib/bbab109.
- [31] JIN W, BARZILAY R, JAAKKOLA T. Junction tree variational autoencoder for molecular graph generation[C]//DY J, KRAUSE A. Proceedings of Machine Learning Research: Vol. 80 Proceedings of the 35th International Conference on Machine Learning. PMLR, 2018: 2323-2332.
- [32] SIMONOVSKY M, KOMODAKIS N. Graphvae: Towards generation of small graphs using variational autoencoders[C]//Artificial Neural Networks and Machine Learning – ICANN 2018. Cham: Springer International Publishing, 2018: 412-422.
- [33] ZANG C, WANG F. Moflow: An invertible flow model for generating molecular graphs[C/OL]//KDD '20: Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. New York,

-
- NY, USA: Association for Computing Machinery, 2020: 617–626. DOI: 10.1145/3394486.3403104.
- [34] HOOGEBOOM E, SATORRAS V G, VIGNAC C, et al. Equivariant diffusion for molecule generation in 3D[C]//Proceedings of Machine Learning Research: Vol. 162 Proceedings of the 39th International Conference on Machine Learning. PMLR, 2022: 8867-8887.
- [35] HUANG L, ZHANG H, XU T, et al. Mdm: Molecular diffusion model for 3d molecule generation[A]. 2022.
- [36] VIGNAC C, KRAWCZUK I, SIRAUDIN A, et al. Digress: Discrete denoising diffusion for graph generation[C]//International Conference on Learning Representations. 2023.
- [37] VIGNAC C, OSMAN N, TONI L, et al. Midi: Mixed graph and 3d denoising diffusion for molecule generation[C/OL]//ICLR 2023 - Machine Learning for Drug Discovery workshop. 2023. <https://openreview.net/forum?id=M6Ifac3G4HK>.
- [38] MOREHEAD A, CHENG J. Geometry-complete diffusion for 3d molecule generation[C/OL]//ICLR 2023 - Machine Learning for Drug Discovery workshop. 2023. <https://openreview.net/forum?id=X-tLu3OUE-d>.
- [39] DU W, ZHANG H, DU Y, et al. SE(3) equivariant graph neural networks with complete local frames[C/OL]//Proceedings of Machine Learning Research: Vol. 162 Proceedings of the 39th International Conference on Machine Learning. PMLR, 2022: 5583-5608. <https://proceedings.mlr.press/v162/du22e.html>.
- [40] AVRAHAM O, LISCHINSKI D, FRIED O. Blended diffusion for text-driven editing of natural images[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 18208-18218.
- [41] HO J, SAHARIA C, CHAN W, et al. Cascaded diffusion models for high fidelity image generation[J/OL]. Journal of Machine Learning Research, 2022, 23(47): 1-33. <http://jmlr.org/papers/v23/21-0635.html>.

-
- [42] CAI R, YANG G, AVERBUCH-ELOR H, et al. Learning gradient fields for shape generation[C]//VEDALDI A, BISCHOF H, BROX T, et al. Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 364-381.
 - [43] LUO S, HU W. Score-based point cloud denoising[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 4583-4592.
 - [44] AUSTIN J, JOHNSON D D, HO J, et al. Structured denoising diffusion models in discrete state-spaces[C/OL]//RANZATO M, BEYGELZIMER A, DAUPHIN Y, et al. Advances in Neural Information Processing Systems: Vol. 34. Curran Associates, Inc., 2021: 17981-17993. https://proceedings.neurips.cc/paper_files/paper/2021/file/958c530554f78bcd8e97125b70e6973d-Paper.pdf.
 - [45] HOOGEBOOM E, NIELSEN D, JAINI P, et al. Argmax flows and multinomial diffusion: Learning categorical distributions[C/OL]//RANZATO M, BEYGELZIMER A, DAUPHIN Y, et al. Advances in Neural Information Processing Systems: Vol. 34. Curran Associates, Inc., 2021: 12454-12465. https://proceedings.neurips.cc/paper_files/paper/2021/file/67d96d458abdef21792e6d8e590244e7-Paper.pdf.
 - [46] SAVINOV N, CHUNG J, BINKOWSKI M, et al. Step-unrolled denoising autoencoders for text generation[C/OL]//International Conference on Learning Representations. 2022. <https://openreview.net/forum?id=T0GpzBQ1Fg6>.
 - [47] XIE T, FU X, GANEA O E, et al. Crystal diffusion variational autoencoder for periodic material generation[C/OL]//International Conference on Learning Representations. 2022. https://openreview.net/forum?id=03RLpj-tc_.
 - [48] SHABANI M A, HOSSEINI S, FURUKAWA Y. Housediffusion: Vector floor-plan generation via a diffusion model with discrete and continuous denoising [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 5466-5475.
 - [49] LEI J, DENG C, SHEN B, et al. Nap: Neural 3d articulation prior[A/OL]. 2023. arXiv: 2305.16315.

-
- [50] DABRAL R, MUGHAL M H, GOLYANIK V, et al. Mofusion: A framework for denoising-diffusion-based motion synthesis[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 9760-9770.
- [51] RONNEBERGER O, FISCHER P, BROX T. U-net: Convolutional networks for biomedical image segmentation[C/OL]//NAVAB N, HORNEGGER J, WELLS W M, et al. Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015. Cham: Springer International Publishing, 2015: 234-241. DOI: 10.1007/978-3-319-24574-4_28.
- [52] RAAB S, LEIBOVITCH I, LI P, et al. Modi: Unconditional motion synthesis from diverse data[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 13873-13883.
- [53] LIMNIO S, SELVARAJ P, CUCURINGU M, et al. Sagess: Sampling graph denoising diffusion model for scalable graph generation[A/OL]. 2023. arXiv: 2306.16827.
- [54] NIU C, SONG Y, SONG J, et al. Permutation invariant graph generation via score-based generative modeling[C/OL]//CHIAPPA S, CALANDRA R. Proceedings of Machine Learning Research: Vol. 108 Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics. PMLR, 2020: 4474-4484. <https://proceedings.mlr.press/v108/niu20a.html>.
- [55] HUANG H, SUN L, DU B, et al. Graphgdp: Generative diffusion processes for permutation invariant graph generation[A/OL]. 2022. arXiv: 2212.01842.
- [56] LUO T, MO Z, PAN S J. Fast graph generation via spectral diffusion[A/OL]. 2022. arXiv: 2211.08892.
- [57] CHEN X, LI Y, ZHANG A, et al. Nvdif: Graph generation through the diffusion of node vectors[A/OL]. 2022. arXiv: 2211.10794.
- [58] YANG L, ZHANG Z, ZHANG W, et al. Score-based graph generative modeling with self-guided latent diffusion[EB/OL]. 2023. <https://openreview.net/forum?id=AykEgQNPJEK>.

-
- [59] KONG L, CUI J, SUN H, et al. Autoregressive diffusion model for graph generation[EB/OL]. 2023. <https://openreview.net/forum?id=98J48HZXxd5>.
- [60] CHEN X, HE J, HAN X, et al. Efficient and degree-guided graph generation via discrete diffusion modeling[A/OL]. 2023. arXiv: 2305.04111.
- [61] WEN L, WEI X. Hyperbolic graph diffusion model for molecule generation [A/OL]. 2023. arXiv: 2306.07618.

硕士研究生期间的科研成果

论文:

XU C, ZHANG Y, WANG W, DONG L. Pursuit and evasion strategy of a differential game based on deep reinforcement learning[J]. Frontiers in Bioengineering and Biotechnology, 2022, 10: 827408.

ZHANG Y, **XU C**, WU X, ZHANG Y, DONG L, WANG W. LFGCF: Light folksonomy graph collaborative filtering for tag-aware recommendation[J]. Expert Systems with Applications, 2022, Under Review.

XU C, ZHANG Y, CHEN H, DONG L, WANG W. A fairness-aware graph contrastive learning recommender framework for social tagging systems[J]. Information Sciences, 2023: 119064.

课题:

面向分布式异构计算系统内存池化关键技术, 国家重点研发计划之先进计算与新兴软件。

竞赛:

“华为杯”第十八届中国研究生数学建模竞赛, 三等奖, 排名: 1/3。

第五届全国应用统计专业学位研究生案例大赛, 三等奖, 排名: 1/3。

OGB-LSC @NeurIPS 2022 (PCQM4Mv2 Track), NO.11, 排名: 1/5。